

# **Redes Neurais Informadas por Física em Mecânica Computacional**

Tópicos Especiais em Mecânica dos Sólidos

Eng. Paulo de Souza Silva e Prof. Dr. Wallace Gusmão

Junho de 2025







# Revisão Inicial


Redes Neurais



# Uma breve ideia das NNs - Arquitetura




Fully-connected neural network



Parallel fully-connected network

# Uma breve ideia das NNs - Arquitetura



## Redes Neurais Convolucionais

Convolutional Neural Networks from Scratch


<https://youtu.be/jDe5BAsT2-Y?si=tySCQonvLXk9Cvfm>

A máquina de Aprendizado Extremo:


<https://computacaointeligente.com.br/algoritmos/maquina-de-aprendizado-extremo/>

**Extreme Learning Machine**

# Uma breve ideia das NNs - Arquitetura



**Graph Convolution Network**



**Kolmogorov-Arnold Network**

Graph Convolutional Network

<https://paperswithcode.com/method/gcn>

Redes Grafos Neurais

KAN: Kolmogorov-Arnold Networks

<https://arxiv.org/abs/2404.19756>



# Variações da PINN

As 10 variações da PINN "Forte"



# Tipos de PINNs “Forte”

|                                                                                     | Métodos   | Tipo de Rede                | Função de Teste               |
|-------------------------------------------------------------------------------------|-----------|-----------------------------|-------------------------------|
|                                                                                     | PIELM     | Extreme Learning Machine    | Delta de Dirac                |
|                                                                                     | VPINNs    | Fully Connected             | Funções de Peso Mistas        |
|                                                                                     | cPINN     | Fully Connected             | Delta de Dirac                |
|                                                                                     | hp-VPINNs | Fully Connected             | Polinômios Ortogonais         |
|    | PhyGeoNet | Convolutional Network (CNN) | Delta de Dirac                |
|                                                                                     | XPINN     | Fully Connected             | Delta de Dirac                |
|    | PIGCN     | Graph Convolution (GCN)     | Espaço de Funções Tentativa   |
|   | SPINN     | Radial Basis Function       | Espaço de Funções Tentativa   |
|                                                                                     | BINN      | Fully Connected             | Soluções Fundamentais de EDPs |
|  | KINN      | Kolmogorov Arnold Network   | Delta de Dirac                |


Adaptado de Wang et al (2024a)

# PIELM: PI Extreme Learning Machine

Esta abordagem combina os princípios do PINN com a arquitetura e o algoritmo de treinamento das Extreme Learning Machines (ELM).

No PIELM, os pesos e vieses da **camada de entrada** da rede neural são **atribuídos aleatoriamente e permanecem fixos**, enquanto os pesos da **camada de saída** são calculados **analiticamente** minimizando a função de perda física.

Isso torna o treinamento significativamente **mais rápido** do que em PINNs tradicionais que usam otimização iterativa para todos os parâmetros.



**Obs:** Pseudo-Inversa de Penrose (pinv)

$$H(x, y)\vec{c} = \vec{f}$$


$$\vec{c} = pinv(H)\vec{f}$$



# VPINN: Variational PINN

Ao contrário do PINN tradicional que se baseia na forma **forte (colocação) da EDP**, o VPINN incorpora a **formulação variacional (forma fraca) da EDP** na função de perda.

Isso geralmente envolve a **integração dos resíduos** da EDP ponderados por funções de teste, o que pode reduzir a ordem dos operadores diferenciais necessários e, em alguns casos (para redes rasas), permitir o cálculo analítico dessas integrais.



$$(\mathcal{L}^q u_{NN}(\mathbf{x}), v(\mathbf{x}))_\Omega = (f(\mathbf{x}), v(\mathbf{x}))_\Omega$$

$$u(\mathbf{x}) = h(\mathbf{x}), \quad \mathbf{x} \in \partial\Omega$$

$$Residual^v = \mathcal{R} - F - r^b,$$

$$\mathcal{R} = (\mathcal{L}^q u_{NN}, v)_\Omega, \quad F = (f, v)_\Omega,$$

Kharazmi (2019)

Espaço de Tentativa: Redes Neurais  
 Espaço de Teste: Polinômios de Legendre  
 $(\cdot, \cdot)$  Produto interno

# cPINN: Conservative PINN

O cPINN introduz a ideia de **decomposição de domínio** para resolver EDPs, utilizando leis de conservação.

Ele divide o domínio computacional em vários subdomínios, **cada um com sua própria rede neural**.

Impõe **condições de continuidade** (incluindo continuidade de fluxo conservativo) nas interfaces entre os subdomínios para "**costurar**" a **solução global**, permitindo maior flexibilidade na arquitetura local e paralelização.






fig. 4.  $N_{sd}$  sub-domain numbering, cPINN solution and point-wise error (top row, left to right), and comparison of exact and predicted solution at  $t = 0.14, 0.69$  and  $0.99$  locations (bottom row) for the one-dimensional viscous Burgers equation. The vertical blue lines give the location of interface positions.





Fig. 9. (Left to right) 12 sub-domains numbering, exact solution, cPINN solution, and point-wise error of two-dimensional Burgers equation.


# hp-VPINN: hp - Variational PINN

Esta estratégia **estende o VPINN** incorporando **decomposição de domínio (h-refinement)** e a capacidade de usar **polinômios de alta ordem localmente (p-refinement)** como funções de teste dentro de cada subdomínio.




A principal diferença é a combinação da formulação **variacional com decomposição de domínio e funções de teste locais** baseadas em polinômios, permitindo adaptabilidade e refinamento local da solução de forma mais explícita e controlada do que no PINN global.





1 elemento



3 elementos



1 elemento




64 elementos

# PhyGeoNet: PI geometry-adaptive convolutional NNs

PhyGeoNet utiliza **redes neurais convolucionais (CNNs)** e é projetado para lidar com EDPs em domínios com **geometrias irregulares e malhas não uniformes**.

Ele emprega transformações de coordenadas, com **mapeamentos elípticos**, para levar a geometria complexa para um domínio de referência regular onde as **operações de convolução** padrão podem ser aplicadas.



Gao (2020)



# XPINN: eXtended PINN

XPINN é uma estrutura de **decomposição de domínio generalizada** que permite dividir o domínio computacional de **forma arbitrária no espaço e no tempo** para resolver qualquer tipo de EDP, **não se limitando a leis de conservação** como cPINN.

Ele usa redes neurais separadas em cada subdomínio e as conecta por meio de **condições de interface baseadas na continuidade residual** e/ou na solução média, facilitando a paralelização espaço-temporal.







Figure 2: One-dimensional viscous Burgers equation: Residual points in subdomain 1 (blue stars) and subdomain 2 (yellow circles). Red line represent the dolphin shaped interface, which separates the two subdomains, and black cross represents the training data points from initial and boundary conditions.








# SPINN: Sparse, Physics-Based, and Partially Interpretable Neural Networks

SPINN propõe uma nova classe de redes neurais esparsas que se inspiram em **métodos sem malha (meshless)**.

A arquitetura da rede é projetada para emular uma aproximação sem malha usando **funções base localizadas (kernels)**.

Podem ser representadas por uma **pequena rede neural interna**, tornando a rede geral parcialmente interpretável e adaptável a descontinuidades e gradientes acentuados através da adaptação da posição e largura dos kernels.







Ramabathiran (2021)

# PIGCN: PI Graph Neural Galerkin Networks

Este framework discreto combina **redes neurais convolucionais de grafos (GCNs)** com a formulação **variacional de Galerkin** para resolver EDPs em malhas não estruturadas.

As GCNs operam **diretamente nos dados da malha** (representada como um grafo), e a função de perda é construída a partir da forma variacional da EDP.

Permitem a imposição rigorosa de condições de **contorno essenciais** e o tratamento de **geometrias complexas** de forma eficiente em malhas não estruturadas.



Gao et al (2022)




# BINN: Boundary Integral type Neural Network

BINN reformula a solução de EDPs utilizando **equações integrais de contorno**.


Em vez de aproximar a solução no domínio inteiro, o BINN aproxima as incógnitas (campo e/ou suas derivadas) **apenas no contorno** utilizando uma rede neural.

A função de perda é definida pelos **resíduos das equações integrais de contorno**, que naturalmente incorporam as condições de contorno e **reduzem a dimensão do problema**.

Sun et al (2023)



Essential boundary  $\Gamma_1$




Natural boundary  $\Gamma_2$

DCM loss = PDE loss on  $\Omega$   
+ boundary loss on  $\Gamma_1$   
+ boundary loss on  $\Gamma_2$


DRM loss = energy functional on  $\Omega$  &  $\Gamma_2$   
+ boundary loss on  $\Gamma_1$

BINN loss = BIE loss on  $\Gamma_1$  &  $\Gamma_2$

Equação de Laplace 2D



Fluxo Potencial 2D






# KINN: Kolmogorov-Arnold-Informed Neural Networks

KINN ou PIKAN é uma abordagem que substitui a rede neural tradicional (MLP) tipicamente usada no framework PINN por **Kolmogorov-Arnold Networks (KANs)**.

Essa substituição é aplicada a diferentes formulações de EDPs (**forte, energética, inversa**), buscando melhorar a **precisão**, a **interpretabilidade** e o tratamento de problemas com múltiplos scales ou descontinuidades devido às propriedades das KANs baseadas em **B-splines**.



Wang et al (2024b)



# PINNs Energéticas

Deep Energy Methods (DEMs)

# Afinal, o que são DEMs?

São PINNs em que a **função de perda** é baseada na **função potencial de energia do sistema**, sendo normalmente utilizada em problemas de Hiperelasticidade. No entanto pode ser usada em problemas de elasticidade linear, fratura etc. [Samaniego, 2019; Nguyen-Tahn, 2019; Kollmannsberger, 2021].

## Método de Rayleigh-Ritz ou Imposição da aproximação na forma fraca\*

Para exemplificar, tomamos como base da Mecânica dos Sólidos 2 ou Resistência dos Materiais princípios de energia como o PTV e o Teorema de Castigliano.

Podemos definir um funcional de energia:

$$\Pi = U_i - U_e$$

Em que  $U_i$  é a energia interna e  $U_e$  a energia externa, para um problema de elasticidade linear têm-se que:

$$U_i = \frac{1}{2} \int_{\Omega} \varepsilon : \mathbb{C} : \varepsilon \, dx \Rightarrow \int_{\Omega} \frac{1}{2} \sigma^T \varepsilon \, dx$$

\*A forma fraca aqui está associada a diminuir o grau da derivada do problema, mas sem a ponderação como nos métodos variacionais/Galerkin.

# Afinal, o que são DEMs?

## Problema de uma barra

Vamos considerar que as propriedades e a área da seção não variam, então temos:

$$\frac{d}{dx} \left( \frac{du}{dx} \right) = - \frac{q(x)}{EA} = u''$$

## Problema de tração

$$u = \frac{PL}{EA} \Rightarrow du = \frac{Pdx}{EA} \Rightarrow \frac{P}{A} = E \frac{du}{dx} \Rightarrow \sigma = Eu' \quad \varepsilon = u'$$

Substituindo na equação do slide anterior

$$U_i = \int_0^L \int_A (Eu'u') dA dx \rightarrow U_i = \frac{1}{2} \int_0^L EA(u')^2 dx$$

**Para uma viga em flexão:** a equação inicialmente tem uma derivada de quarta ordem que se reduz a

$$U_i = \frac{1}{2} \int_0^L EI(v'')^2 dx$$

Aqui as expressões das energias externas foram desconsideradas por praticidade, mas elas são necessárias para resolver os problemas num todo, ver Kollmannsberger (2021) Cap. 6.

# Afinal, o que são DEMs?

Equações governantes de um problema de hiper-elasticidade

Equilibrium:  $\nabla_X \cdot \mathbf{P} + \mathbf{f}_b = \mathbf{0}$ ,

Dirichlet boundary :  $\mathbf{u} = \bar{\mathbf{u}}$  on  $\partial B_u$ ,

Neumann boundary :  $\mathbf{P} \cdot \mathbf{N} = \bar{\mathbf{t}}$  on  $\partial B_t$ ,

$$\mathbf{F} = \nabla_X \boldsymbol{\varphi}(\mathbf{X}),$$

$$\mathbf{P} = \frac{\partial \Psi}{\partial \mathbf{F}},$$

$$\text{Neo-Hookean: } \Psi(I_1, J) = \frac{1}{2} \lambda [\log(J)]^2 - \mu \log(J) + \frac{1}{2} \mu (I_1 - 3),$$

$$\Pi(\boldsymbol{\varphi}) = \int_B \Psi dV - \int_B \mathbf{f}_b \cdot \boldsymbol{\varphi} dV - \int_{\partial B_t} \bar{\mathbf{t}} \cdot \boldsymbol{\varphi} dA.$$

$$\min_{\boldsymbol{\varphi} \in H} \Pi(\boldsymbol{\varphi}),$$

**F:** Gradiente de Deformação | **P:** 1º Tensor de Piola-Kirchhoff | **Ψ:** Energia de Deformação Específica

**I<sub>1</sub>:**Primeiro Invariante | **J:** Segundo Invariante



# Tipos de DEMs

| Métodos   | Tipo de Rede              | Princípio Energético           |
|-----------|---------------------------|--------------------------------|
| Deep Ritz | Extreme Learning Machine  | Variacional                    |
| DEM       | Fully Connected           | Mínimo Potencial de Energia    |
| PFNN      | Fully Connected           | Variacional                    |
| mDEM      | Fully Connected           | Forma Mista                    |
| P-DEM     | Fully Connected           | Mínimo Potencial de Energia    |
| CENN      | Fully Connected           | Mínimo Potencial de Energia    |
| GCN-DEM   | Graph Convolution (GCN)   | Mínimo Potencial de Energia    |
| PIRBN     | Radial Basis Function     | Mínimo Potencial de Energia    |
| DCEM      | Fully Connected           | Mínimo Complementar de Energia |
| KINN      | Kolmogorov Arnold Network | Mínimo Potencial de Energia    |

Adaptado de Wang et al (2024a)



# Vídeos e Referências

# Vídeos Recomendados

## Vídeos

Physics Informed Neural Networks (PINNs): "PyTorch" Solve Physical Systems with Deep Neural Networks: <https://youtu.be/MtHvs5FvtME?si=MeGVe9HF8pCkKN2j> <Acesso em: 13/05/2025>

Physics Informed Neural Networks for Fluid Mechanics:  
[https://youtu.be/EHrgSPHZG3Y?si=JUOWe1pC\\_7bt6i18](https://youtu.be/EHrgSPHZG3Y?si=JUOWe1pC_7bt6i18) <Acesso em: 13/05/2025>

## Playlists

Neural Networks / Deep Learning: <https://youtube.com/playlist?list=PLblh5JKOoLUIxGDQs4LFFD--41Vzf-ME1> <Acesso em: 03/06/2025>

Physics Informed Machine Learning:  
<https://youtube.com/playlist?list=PLMrJAKhleNNQ0BaKuBKY43k4xMo6NSbBa> <Acesso em: 06/06/2025>

Physics Informed Neural Networks (PINNs):  
<https://youtube.com/playlist?list=PLM7DTyYjZGuLmg3f6j40fEF18jyQmYsC2> <Acesso em: 06/06/2025>

# Referências

Dwivedi (2019) Physics Informed Extreme Learning Machine (PIELM)–A rapid method for the numerical solution of partial differential equations

Estevão et al (2023) Physics-informed Neural Networks For Solving Elasticity Problems

Gao et al (2020): PhyGeoNet: Physics-Informed Geometry-Adaptive Convolutional Neural Networks for Solving Parameterized Steady-State PDEs on Irregular Domain

Gao et al (2022): Physics-informed graph neural Galerkin networks: A unified framework for solving PDE-governed forward and inverse problems

Haghighat et al (2020): A physics-informed deep learning framework for inversion and surrogate modeling in solid mechanics

Hu et al (2024): Physics-informed Neural Networks (PINN) for computational solid mechanics: Numerical frameworks and applications

Jagtap (2020): Conservative physics-informed neural networks on discrete domains for conservation laws: Applications to forward and inverse problems

# Referências

Jagtap (2021): Extended physics-informed neural networks (XPINNs): A generalized space-time domain decomposition based deep learning framework for nonlinear partial differential equations

Kharazmi (2019) VPINNs: Variational Physics-informed Neural Networks For Solving Partial Differential Equations

Kharazmi (2020) hp-VPINNs: Variational Physics-Informed Neural Networks With Domain Decomposition

Kollmannsberger et al (2021): Deep Learning in Computational Mechanics - An Introductory Course

Liu et al (2025) – KAN: Kolmogorov – Arnold Networks

Nentidis (2022) - Evaluation of Physics Informed Neural Networks in engineering simple structural analysis problems

Nguyen-Than (2019) - A deep energy method for finite deformation hyperelasticity

# Referências

Raissi (2017) - Physics Informed Deep Learning (Part I): Data-driven Solutions of Nonlinear Partial Differential Equations

Ramabathiran (2021)- SPINN: Sparse, Physics-based, and partially Interpretable Neural Networks for PDEs

Samaniego (2019) - An Energy Approach to the Solution of Partial Differential Equations in Computational Mechanics via Machine Learning: Concepts, Implementation and Applications

Vu-Quoc & Humer (2023): Deep Learning Applied to Computational Mechanics: A comprehensive Review, State of the Art, and the Classics

Wang et al (2024a)- Artificial intelligence for partial differential equations in computational mechanics: A review

Wang et al (2024b)- Kolmogorov-Arnold-Informed neural network: A physics-informed deep learning framework for solving forward and inverse problems based on Kolmogorov–Arnold Networks





Obrigado!